

Perhitungan Biaya AI Claude vs Gemini

Panduan internal: model bisnis YFD First Aid, kuota AI, dan proyeksi skala pengguna

Dokumen: PERHITUNGAN_BIAYA_AI_CLAUDE_VS_GEMINI | Tanggal: Juli 2026 | Kurs acuan: Rp 16.500 / USD

1. Ringkasan eksekutif

YFD First Aid memakai AI untuk **(A) parsing transaksi bot Telegram** dan **(B) Doctor's Note / insight dashboard**. Saat ini provider utama adalah **Claude (Haiku + Sonnet)**. Dokumen ini membandingkan biaya dengan **Google Gemini** dan menjelaskan dampak model **sekali bayar (lifetime)** vs **biaya API berulang**.

Poin penting: Angka **Rp 5.000/bulan per user** di sistem YFD adalah **plafon kuota internal**, bukan tagihan Claude/Gemini ke provider. Setelah kuota habis, user tetap bisa catat transaksi (mode biasa) tanpa biaya API tambahan.

2. Harga API resmi (per 1 juta token)

Sumber: Anthropic Platform Docs & Google Gemini API Pricing (Juli 2026). Input dan output dibilling terpisah.

Model	Input / 1M token	Output / 1M token	Setara use case YFD
Gemini 2.5 Flash-Lite	\$0,10	\$0,40	Parsing bot (paling murah)
Gemini 3 Flash Preview	\$0,50	\$3,00	Parsing + multimodal ringan
Claude Haiku 4.5 YFD sekarang	\$1,00	\$5,00	Parse bot + insight ringan
Gemini 3.5 Flash	\$1,50	\$9,00	Agentic / coding
Gemini 3.1 Pro (≤200K prompt)	\$2,00	\$12,00	Reasoning kompleks
Claude Sonnet 4.6 Portal insight	\$3,00	\$15,00	Doctor's Note premium

Pola umum: output ≈ 5× input. Gemini Flash-Lite bisa **8–10× lebih murah** dari Claude Haiku untuk workload serupa.

3. Estimasi biaya per aksi (YFD)

3.1 Parse transaksi bot (teks)

Per request kira-kira: **~2.500 token input** (system prompt + aturan kategori) + **~150 token output** (JSON)

Provider / model	Biaya per parse (USD)	Biaya per parse (IDR)	Per 1.000 parse
Gemini 2.5 Flash-Lite	~\$0,0003	~Rp 5	~Rp 5.000
Gemini 3 Flash Preview	~\$0,0017	~Rp 28	~Rp 28.000
Claude Haiku 4.5	~\$0,0033	~Rp 54	~Rp 54.000

3.2 Doctor's Note bulanan (dashboard AI)

Per generate kira-kira: **~3.000 token input + ~800 token output** | Frekuensi: **1× per user per bulan** (dengan cache)

Provider / model	Biaya per generate (IDR)	Jika dijual Rp 10.000/bulan
Gemini 2.5 Flash-Lite	~Rp 10–15	Margin ~99%
Claude Haiku 4.5	~Rp 120–200	Margin ~98%
Claude Sonnet 4.6	~Rp 350–500	Margin ~95%

4. Kuota AI di sistem YFD (bukan tagihan provider)

Setting	Nilai default	Artinya
AI_QUOTA_MONTHLY_IDR	Rp 5.000	Plafon kuota AI per user per bulan
AI_COST_TEXT_PARSE_IDR	Rp 10	1 parse teks = Rp 10 (akuntansi internal)
AI_COST_VISION_PARSE_IDR	Rp 30	1 parse foto struk = Rp 30 (internal)
Maks parse teks/bulan	±500×	Setelah habis → mode biasa (tanpa AI)

Jangan pakai Rp 5.000 sebagai biaya Claude langsung.
Itu batas proteksi bisnis. Biaya API riil tergantung berapa kali user benar-benar memakai AI.

5. Biaya API riil per user per bulan

Asumsi: Claude Haiku untuk parse bot. Kurs Rp 16.500/USD.

Profil user	Parse/bulan	Claude Haiku	Gemini Flash-Lite
Ringan	10	~Rp 540	~Rp 50
Normal	30	~Rp 1.620	~Rp 150
Aktif	100	~Rp 5.400	~Rp 500
Maks kuota	500	~Rp 27.000	~Rp 2.500

6. Model bisnis: sekali bayar vs biaya berulang

6.1 Produk YFD First Aid (lifetime)

Item	Nilai
Harga jual	Rp 199.000 – 299.000 (sekali bayar)
Yang didapat	Bot Telegram + dashboard angka selamanya + kuota AI terbatas
Biaya berulang ke YFD	API AI + server (tergantung pemakaian aktual)

6.2 Runway lifetime vs biaya API (contoh Rp 199.000)

Profil user	Biaya API/bulan (Claude)	Runway dari Rp 199k	Biaya API/bulan (Gemini Lite)	Runway dari Rp 199k
Normal (30 parse)	~Rp 1.620	~10 tahun	~Rp 150	~110 tahun
Aktif (100 parse)	~Rp 5.400	~3 tahun	~Rp 500	~33 tahun
Maks kuota (500 parse)	~Rp 27.000	~8 bulan	~Rp 2.500	~6,5 tahun

Kesimpulan: Lifetime Rp 199–299k *sustainable* jika mayoritas user normal/ringan dan kuota AI tetap dibatasi. Risiko tinggi hanya jika banyak user sangat aktif yang selalu habiskan kuota penuh setiap bulan.

7. Proyeksi skala: 1 juta pengguna

Asumsi: semua user aktif dalam skenario terburuk vs realistis. Hanya biaya API parse (belum server).

Skenario	Parse/user/bulan	Claude Haiku / bulan	Gemini Flash-Lite / bulan
Realistis (30% user aktif, rata-rata 30 parse)	~9 juta total	~Rp 486 juta	~Rp 45 juta
Aktif (semua user 100 parse)	100 juta total	~Rp 5,4 miliar	~Rp 500 juta
Terburuk (semua maks 500 parse)	500 juta total	~Rp 27 miliar	~Rp 2,5 miliar

7.1 Pendapatan sekali bayar vs biaya bulanan

1 juta user × Rp 300.000 = Rp 300 miliar (one-time, bukan per bulan)
Biaya API Claude (skenario aktif): ~Rp 5,4 miliar/bulan → runway ~55 bulan (~4,6 tahun) dari pool pendapatan sekali bayar
Biaya API Gemini Lite (skenario aktif): ~Rp 500 juta/bulan → runway ~600 bulan (~50 tahun)

Tanpa langganan berulang, model lifetime akan **terkurus** pada skala besar + user sangat aktif. Solusi: kuota AI (sudah ada) + langganan Doctor's Note Rp 10.000/bulan.

8. Rekomendasi Doctor's Note — Rp 10.000/bulan

Layer	Harga	Isi
YFD First Aid (lifetime)	Rp 199–299k	Bot + dashboard angka (KPI, bucket, grafik, Pulse) — tanpa Doctor's Note AI penuh
Doctor's Note Bulanan	Rp 10.000/bulan	Analisa personal dr. Financial: ringkasan, interpretasi, prioritas aksi
FTSA Premium	Rp 50.000 / 12 bln	Behavioral FTSA — terpisah dari Doctor's Note transaksi

8.1 Simulasi Doctor's Note subscription

Subscriber	Pendapatan/bulan	Biaya API (Claude)	Biaya API (Gemini Lite)
100	Rp 1.000.000	~Rp 15–50 rb	~Rp 1–2 rb
1.000	Rp 10.000.000	~Rp 150–500 rb	~Rp 10–20 rb
10.000	Rp 100.000.000	~Rp 1,5–5 juta	~Rp 100–200 rb

Margin Doctor's Note sangat sehat di kedua provider. Rp 10.000/bulan lebih dari cukup menutup biaya API per user.

9. Rekomendasi strategi provider

Fase	Provider	Alasan
Pilot (<500 user)	Claude Haiku	Stabilitas JSON + aturan konteks sudah teruji; biaya masih kecil (puluhan ribu/bulan)
Growth (500–10.000 user)	Claude Haiku + kuota ketat	Pertahankan akurasi; pantau biaya bulanan di dashboard Anthropic
Scale (10.000+ user)	Gemini Flash-Lite (parse bot)	Hemat 80–90%; perlu uji ulang akurasi kategori konteks
Doctor's Note premium	Claude Haiku/Sonnet	Insight berkualitas; frekuensi rendah (1×/bulan) → biaya tetap kecil

10. Keputusan yang perlu disetujui klien

1. **Lifetime** mencakup dashboard angka + kuota AI terbatas — bukan AI unlimited.
2. **Doctor's Note** dijual terpisah Rp 10.000/bulan (cashflow berulang).
3. **FTSA Premium** (Rp 50k/12 bln) tetap produk behavioral terpisah.
4. Migrasi ke **Gemini** dipertimbangkan saat user aktif > 5.000 atau biaya API > Rp 5 juta/bulan.
5. Pembayaran langganan via **Midtrans otomatis** (bukan transfer manual admin).

11. Glosarium

Istilah	Arti
Token	Unit billing AI (~1 token ≈ ¾ kata Bahasa Indonesia)
Parse	1 kali AI membaca & mengkategorikan 1 catatan transaksi
Doctor's Note	Interpretasi personal dr. Financial di dashboard bulanan
Kuota internal	Batas pemakaian AI per user di sistem YFD (Rp 5.000/bln)
Lifetime	Sekali bayar — lisensi bot & dashboard tidak expired
MTok	1 juta token

Your Financial Doctor (YFD) — Dokumen internal perencanaan biaya AI.
Angka estimasi berdasarkan harga publik provider Juli 2026. Biaya aktual dapat berbeda tergantung panjang prompt, cache, batch API, dan pola pemakaian user. Verifikasi harga terbaru di platform.claude.com dan ai.google.dev.
File pendamping: PERHITUNGAN_BIAYA_AI_CLAUDE_VS_GEMINI.html (buka di browser → Cetak → Simpan sebagai PDF)